# 一、服务器连接

## - 1 - 推荐一个云服务器平台：恒源云


可以看到 `24G` 显存的 `3090` 只需要 `0.9` 元/小时
不需要大显存的组也可以换成 `3060` or `3080`，也都很便宜

---

## - 2 - 镜像的选择


`BERT` 是基于 `PyTorch` 构建的，所以我们在创建服务器时就可直接选择，推荐 `PyTorch==2.0.0 Cuda==11.7.0 Python==3.8` ，比较 `Stable`
然后点击 `创建实例` 就可以了

---

## - 3 - 服务器的连接

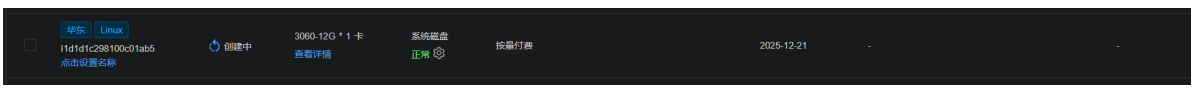


等待创建完成，=>


打开连接工具，首推VSCode，再推荐一个MobaXterm


找到左侧的扩展，搜索 `remote ssh`，安装完成之后左侧会有一个新的图标，点击 `SSH` 右侧的 `+`


=>


然后点击 登陆指令 的第一行 `ssh********` 右侧的 复制 按钮，输入到VSCode的输入框中，按回车



配置文件选第一个，右下角会出现 已添加主机，点击连接

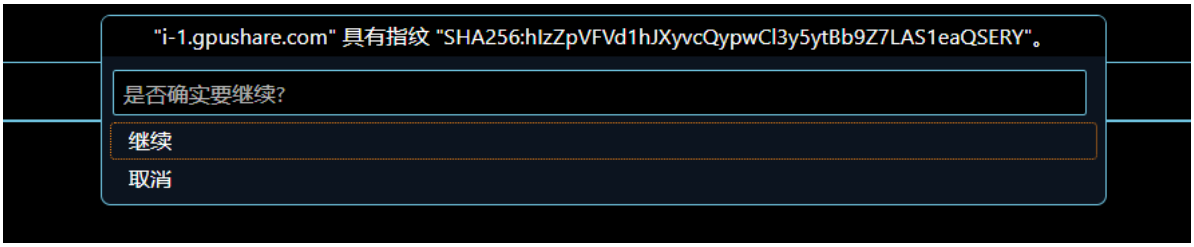


有些可能会出现指纹提示，点 `继续`，有的可能会出现选平台，选 `Linux`


然后再将密码复制过来输入


这样就是连接成功!

---

## MobaXterm连接（自行下载）

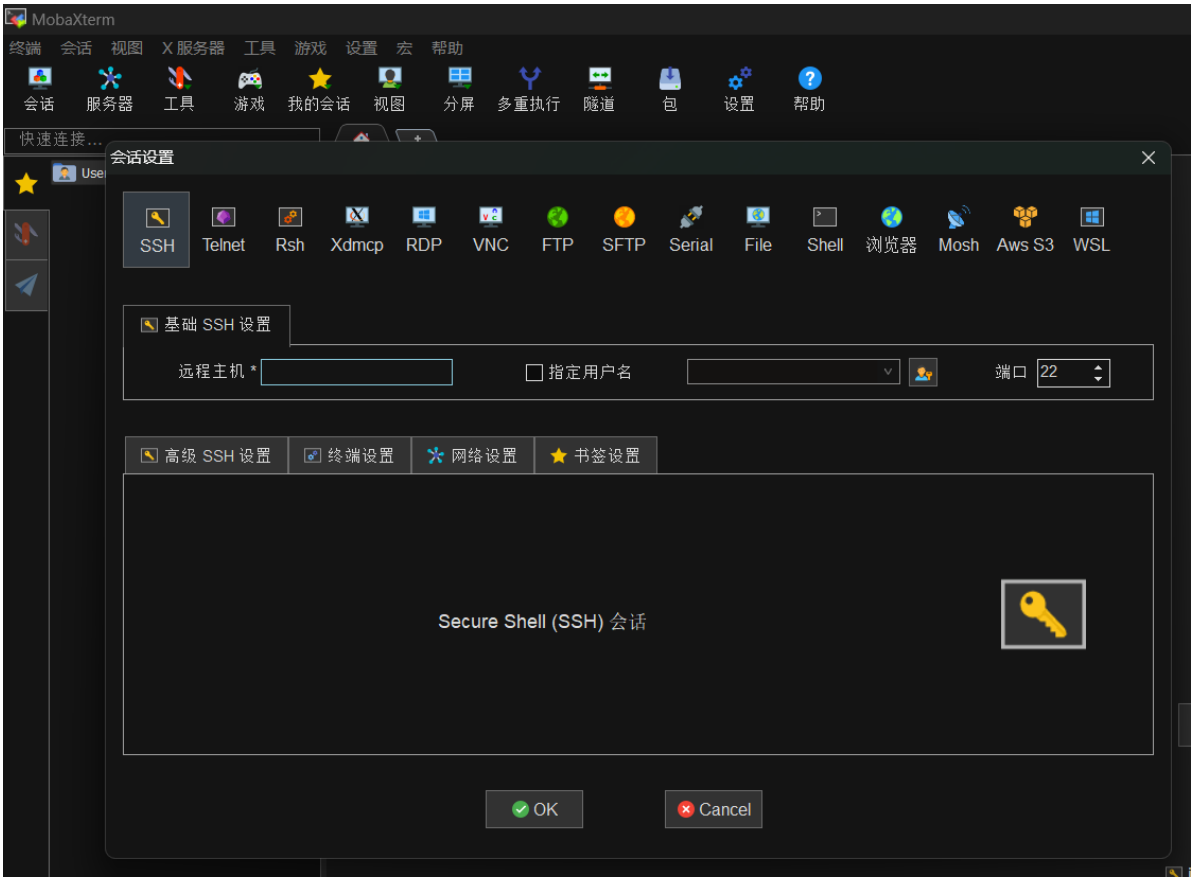


点击 `会话` 的 `SSH`，将登录指令复制下来，然后分别输入 `远程主机`，`指定用户名` 和 `端口号`，例如我的命令是 `ssh -p 34552 root@i-1.gpushare.com`，那我就应该分别填 `i-1.gpushare.com`，`root`，`34552`，然后点击 `OK`，然后按照提示输入密码。注意，MobaXterm的默认粘贴命令是 `Shift+Insert`！！！(可改)

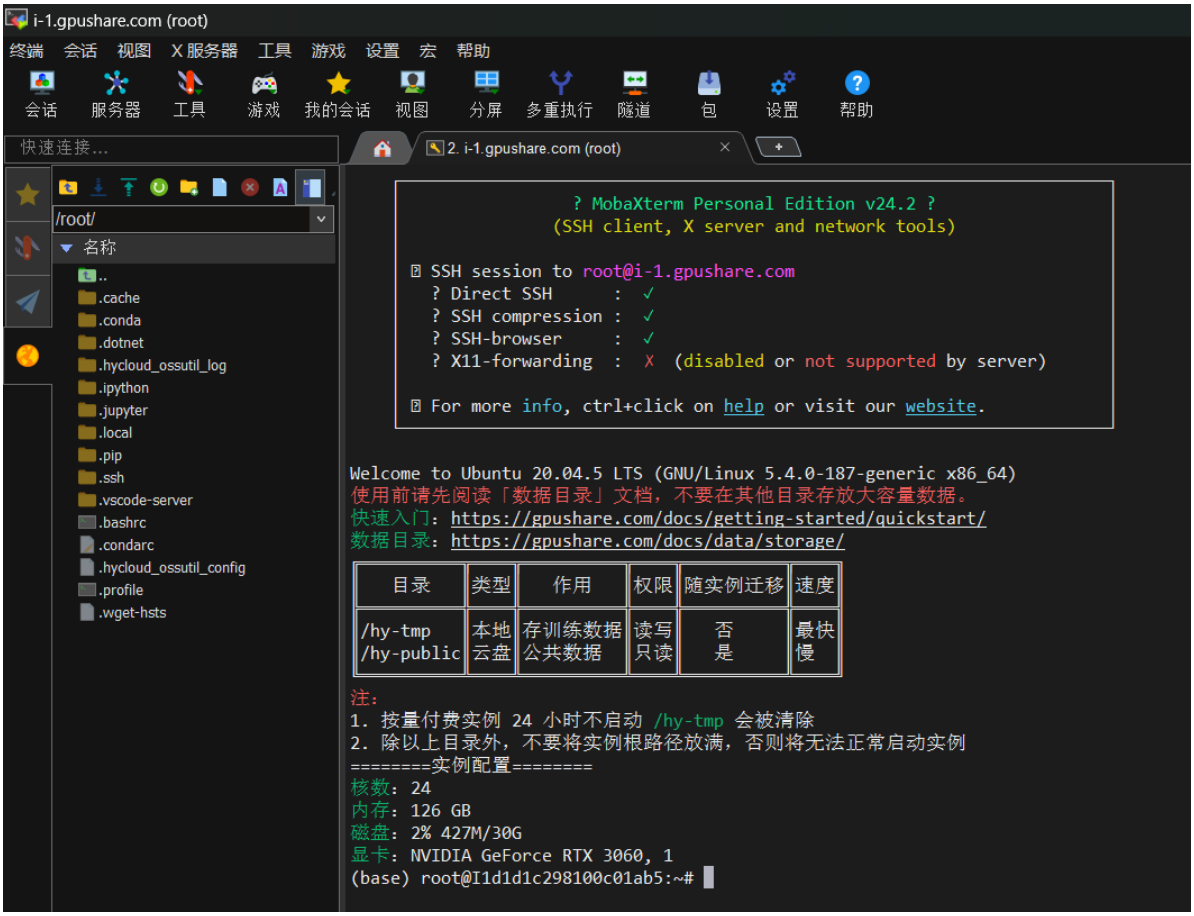


这样就是连接成功了！

> PS：VSCode那么好用，为什么要MobaXterm?
> 因为远程服务器不带显示器，VSCode默认没有X-sever (一种远程显示技术)，但是MobaXterm自带，在一些需要显示图片或者其他任务时，VSCode只能保存下来看，但是MobaXterm可以实时观看。

# 二、BERT环境配置

因为在创建服务器时就已经装好了 `PyTorch`，那么我们配环境中最困难的一步已经让别人帮我们做好了，可以运行以下测试代码：`test_cuda.py`

```
import torch

# 检查CUDA是否可用
cuda_available = torch.cuda.is_available()
print(f"CUDA 是否可用: {cuda_available}")

if cuda_available:
    # 检查当前可用的GPU数量
    gpu_count = torch.cuda.device_count()
    print(f"可用的 GPU 数量: {gpu_count}")
    # 获取当前GPU名称
    for i in range(gpu_count):
        print(f"GPU {i} 名称: {torch.cuda.get_device_name(i)}")
    # 检查当前设备
    current_device = torch.cuda.current_device()
    print(f"当前使用的设备索引: {current_device}")
else:
    print("未检测到可用的 CUDA 设备")
```

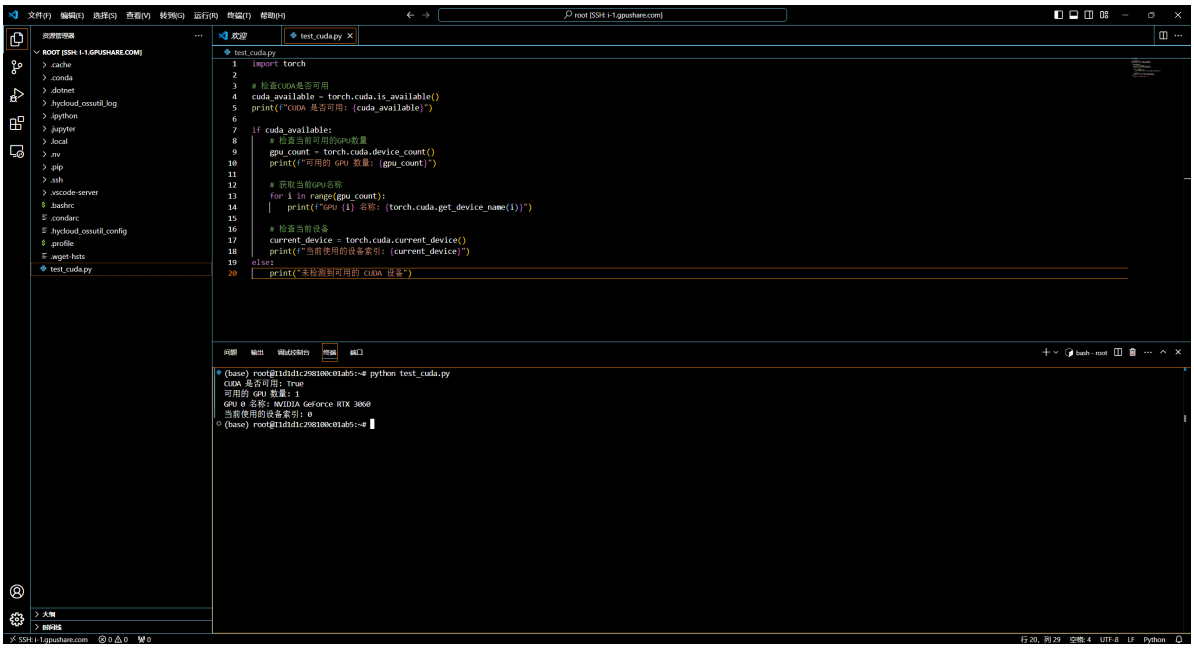


得到如图输出，说明 `torch包` 的 `CUDA` 和 `GPU` 都是可用的

但是想要运行 `BERT`，还要 `pip install transformers`，因为他是基于 `Transformer` 架构的

安装好后，可以运行以下测试代码：`test_bert.py`

```
from transformers import BertTokenizer, BertForSequenceClassification
import torch

model_name = "roberta-base-finetuned-jd-binary-chinese"  # 加载预训练的 tokenizer 和 微调好的情感分类模型(bert-base-chinese)
tokenizer = BertTokenizer.from_pretrained(model_name)
model = BertForSequenceClassification.from_pretrained(model_name)
```

```python
# 移动模型到 GPU
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model.to(device)

# 准备输入的文本 (中文情感分析)
def predict_sentiment(text):
    # 编码输入
    inputs = tokenizer(text, return_tensors='pt', padding=True, truncation=True,
max_length=512)
    # 将输入移动到 GPU
    inputs = {key: value.to(device) for key, value in inputs.items()}
    # 模型推理 (不计算梯度)
    with torch.no_grad():
        outputs = model(**inputs)
    # 获取模型的输出 logits 并将其转换为概率
    logits = outputs.logits
    probs = torch.softmax(logits, dim=-1)
    # 获取最大概率的类别 (0: 消极, 1: 积极)
    sentiment = torch.argmax(probs, dim=-1).item()
    # 返回情感类别和相应的概率
    return "积极" if sentiment == 1 else "消极", probs

# 测试文本
text = "今天的天气真好，我感到非常开心！"
# text = input("请输入测试文本：")

# 预测情感
sentiment, probability = predict_sentiment(text)
print(f"文本: {text}")
print(f"预测的情感: {sentiment}")
print(f"概率: {probability}")
```

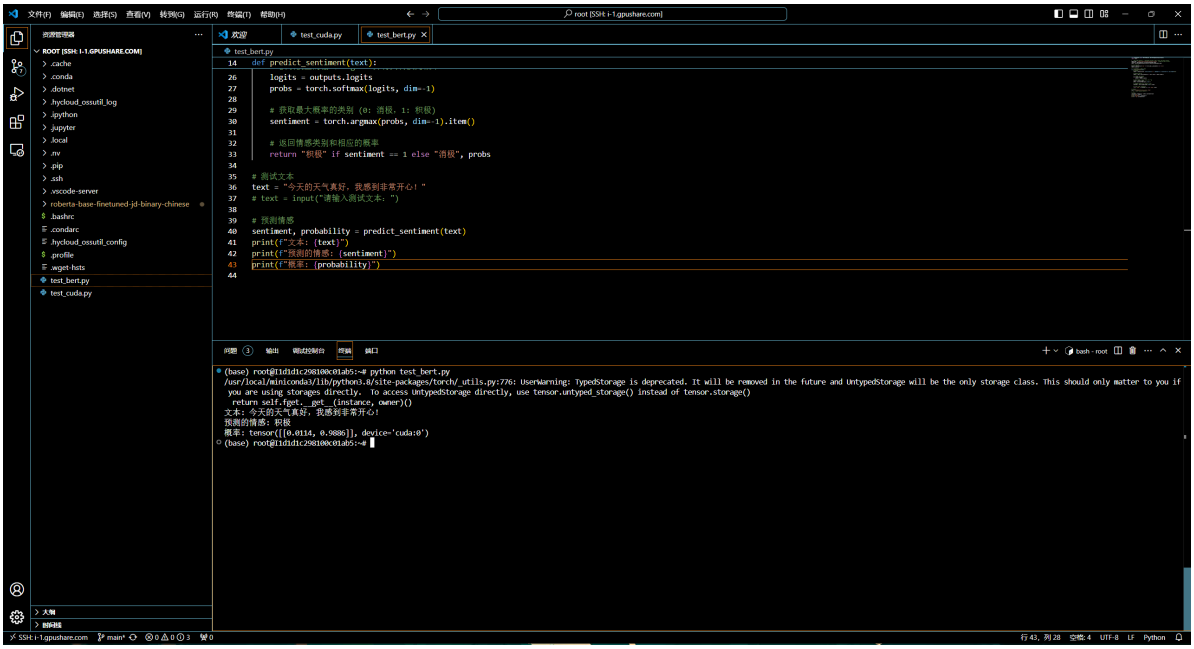


得到如图输出，就说明 `BERT` 的基础环境也已经配好了！

> 着手开始构建属于自己的模型吧！

# 附录

1. 如果服务器连接不上，请核对要填的各个信息是否正确，也可以在 `Windows Terminal` 中直接输入连接命令以及密码，测试命令以及密码是否正确，若否，请重启服务器。
2. 运行 `test_bert.py` 时若报错显示没有或者无法下载 `tokenizer` 以及模型，可以前往 `uer/roberta-base-finetuned-jd-binary-chinese·Hugging Face` 手动下载，其他模型 (大量) 也可在 `Hugging Face` 找到并手动下载。

> `Mail` : `jiuri.z.0796@gmail.com`
> `Date` : `2024/10/18`